



Alicorp · Fábrica Creativa

Plataforma GenAI para contenido consistente con la marca

Ignacio Rubio Montiel

Reto Técnico — Alicorp GenAI

Stack — Backend

- **API:** FastAPI · Python 3.13 · uv
- **Datos:** PostgreSQL + pgvector · SQLAlchemy 2.0 (async) · asyncpg
- **IA:** Groq llama-3.3-70b (texto) · Gemini embedding-001 (embeddings, 768d)
· gemini-flash (visión)
- **Auth:** JWT (HS256) · **RBAC** rol → módulo
- **Observabilidad:** Langfuse — traza cada llamada de IA
- **Infraestructura:** Supabase (Postgres + Storage) · Docker en Render

API: alicorpchallenge-back.onrender.com

Stack — Frontend

- **Framework:** React 19 · Vite · TypeScript (React Compiler)
- **Estado:** TanStack Query · TanStack Table · Zustand
- **HTTP:** Axios
- **Ruteo:** React Router (data router)
- **Auth:** JWT en cookie · navegación y acciones restringidas por **módulo**
- **Infraestructura:** desplegado en Vercel

App: alicorpchallenge-front.vercel.app

Módulos y permisos

Página	Función	Lectura	Escritura
Manuales de marca	Generar manual; chunking de secciones para RAG	Todos	Creador
Anuncios	Generar anuncio del tipo elegido con top-k secciones del manual	Todos	Creador
Auditar texto	Aprobar / rechazar texto	Aprobador A	Aprobador A
Auditar imagen	Subir imagen; IA compara con el manual; decidir	Aprobador B	Aprobador B
Observabilidad	Trazas de IA (Langfuse)	Todos	—

Admin: acceso completo — lectura y escritura en todos los módulos.

Decisiones de diseño

- **Chunking del manual para RAG:** recuperar solo las secciones relevantes por anuncio, no el manual completo.
- **Top-k, no umbral:** la similitud se agrupa en rangos estrechos y variables entre manuales; el ranking siempre entrega k secciones útiles.
- **IA asesora, humano decide:** la auditoría no aprueba ni rechaza sola; la última palabra es del aprobador.
- **Manual híbrido:** anclas fijas (de las que dependen módulos y UI) + secciones flexibles según el producto.
- **Auth propia con RBAC:** roles → módulos en el JWT, verificados por endpoint (sin Supabase Auth).
- **Tablas reutilizables (frontend):** filtros, orden y paginación compartidos en manuales, anuncios y auditorías.

Limitaciones y próximos pasos

Limitaciones

- El top-k puede omitir una sección relevante → un anuncio podría incumplir una restricción de marca (poco frecuente).
- Generación en una sola petición larga (10–30 s abierta): expuesta a *timeouts* de proxy/cliente y sin feedback de progreso.
- *Free tier*: *cold start* en Render (512 MB) y límites de Supabase bajo carga.

Próximos pasos

- **Testing**: unitarias, integración y e2e; evals de RAG y generación.
- **CI/CD**: lint, type-check y tests en cada PR, como *gate* antes del deploy.
- Robustez de IA: reintentos y *fallbacks* Groq/Gemini.
- *Reranker* sobre el top-k.
- Generación automática de imágenes.
- Cola + *workers* (Taskiq + Redis) para generación en segundo plano.
- *Keep-warm*: ping periódico o tier de pago.